

万彬宇

电话: 18809164801 | 邮箱: wanbinyu18@163.com | 现居: 陕西-西安
意向城市: 西安 / 杭州 / 成都 | GitHub: github.com/Wanbinyu | 个人网站: portfolio.wanbinxy.icu



GitHub 与技术输出

- **开源与协作**: 独立维护 **DeepSeek Harness Windows 启动器**, 11 个 Release 累计近 1000 次下载; **OpenRewrite PR 已合并**。
- **AI 工程实践**: 持续使用 Codex、DeepSeek Harness、Grok、Kimi 完成开发、代码审查与测试回归; 多模型后台累计 **80 亿+ Tokens**、**6 万+ 次请求**, 长期跟踪缓存、上下文复用与成本。

公开主页: [GitHub \(github.com/Wanbinyu\)](https://github.com/Wanbinyu)

技术能力

- **RAG 与评测**: 掌握文档加载、切分、Vector/BM25 混合召回、**RRF**、**Cross-Encoder** 重排、引用与拒答; 能够通过 Recall@K、MRR、消融实验和失败样本验证检索策略。
- **LLM 应用开发**: 接入 **DeepSeek**、**Qwen**、**OpenAI** 兼容 API, 处理严格 JSON、Token/缓存统计、超时重试、模型回退与提示词注入。
- **Agent 基础**: 理解 **Tool Calling** 的基本调用流程, 能说明工具参数校验、**调用幂等**、**权限边界与超时重试**; 了解 **MCP**、**ReAct** 等常见模式。
- **后端主线**: 主力使用 **Python/FastAPI**、**Node.js/Express** 构建 REST API 与 Web 产品; 具备 Lua 商业服务端经验及 Java/Spring Boot 项目实践。
- **数据与中间件**: 熟悉 **MySQL**、**Redis** 的事务、索引、锁和缓存更新; 在墨香阁项目中使用 Kafka、Elasticsearch、MinIO 及 Feign/Sentinel。
- **质量与交付**: 使用 **pytest**、**node:test** 进行自动化回归, 掌握 Git、Linux、Docker、Nginx、PM2 及接口测试与日志定位。

核心项目

RAG LangChain Lab | 可验证混合检索与评测系统

2026.07—至今

独立开发 | Python + LangChain/ChromaDB + BM25/RRF + Cross-Encoder + LLM API

项目链接: github.com/Wanbinyu/rag-langchain-lab

项目介绍: 面向中英跨语言知识库问答的可验证 **RAG 实验系统**, 重点研究召回质量、证据边界、拒答与性能取舍, 并用多套迁移/冻结数据集复现实验。

核心功能:

- 基于文件内容哈希维护稳定 **Chunk ID**, 支持新增、修改、删除文档的**增量索引**, 避免知识库变化后全量重建。
- 组合 **Vector / Exact-term / BM25** 多路召回, 经 **RRF** 融合与来源约束后使用多语言 **Cross-Encoder** 重排; 补充相邻 Chunk 上下文并保留各阶段分数。
- 结合重排分数、**Top1/Top2 分差**与段落质量进行证据分级; 仅在证据不足但仍有召回希望时触发 **Query Rewrite/Retry**, 否则拒答, 限制额外延迟与无依据生成。
- 提供 **CLI + 本地 Web 控制台**, 输出命中文档、来源、各阶段分数、证据状态、检索/生成耗时与失败原因, 支持逐链路诊断。

技术亮点:

- **消融与性能取舍**: 对 **Dense**、**Hybrid/BM25+RRF**、**Cross-Encoder** 进行消融; 在第二领域将候选池从 **18 收紧至 6**, P50 由 1258.2 ms 降至 **957.0 ms (约 24%)**, Recall@3、MRR 与 22/22 证据决策保持不变。
- **可信评测**: 除开发/校准集外, 建立 **22 题迁移集**、**30 题冻结集**和 **12 题回答审计**; 冻结集首次综合证据决策 **24/30**, 保留 6 个失败且不再调参, 逐题记录来源、证据状态与引用有效性。
- **真实回归与工程验证**: 中英开发/校准集 Recall@3 **63/65 (96.92%)**、MRR **0.9128**、综合证据决策 **82/85 (96.47%)**; 当前代码 **65 项测试与 26 个子测试全部通过**, 并接入 GitHub Actions。

核心项目

Resume Fit AI | 简历与岗位 JD 定向优化器

2026.08

独立开发 | Node.js + Express + DeepSeek/Qwen/OpenAI API + DOCX/PDF + Nginx + PM2

项目链接: jianli.wanbinxy.icu

项目介绍: 面向求职用户的 **AI 简历优化 Web 产品**, 将原简历、目标方向与岗位 JD 组合分析, 输出诊断和可编辑、可导出的定向简历。

核心功能:

- 支持 PDF、DOCX、TXT 上传解析, 提供快速诊断和完整生成两种模式, 可在线编辑、**A4 实时预览并导出多种格式**。
- 实现 **JD 关键词匹配**、逐项目保留/强化/替换建议, 并生成**求职信**与针对性**面试题**。
- 异步任务支持进度查询、取消、重试和幂等处理**, 避免重复提交造成结果错乱。

技术亮点:

- 模型适配与保真修复**: 统一封装 DeepSeek、Qwen、OpenAI 兼容接口, 处理超时、429/5xx 重试、**Token 统计**与严格 **JSON 解析**; 按栏目和技术词覆盖度触发一次保真修复并择优返回。
- 异步任务与数据生命周期**: 自研内存任务队列, 支持并发/排队上限、进度轮询、取消和刷新恢复; 使用 **X-Idempotency-Key** 防止重复建任务, 以随机 **Task Token** 鉴权; 任务结束后清除原简历和 JD, 结果默认保留 **15 分钟**。
- 安全边界**: 通过 **NFKC**、不可见字符清理及 URL/Base64 解码扫描拦截提示词注入; 通过随机安全标记检测提示泄露, 并对输出执行**字段白名单**、长度限制和前端转义。
- 可观测与验证**: 记录成功率、耗时、超时和 Token 用量; **node:test** 覆盖队列、幂等、重试、导出、注入和配置校验, **27 项测试并全部通过**; 使用 **Nginx + PM2** 完成生产部署。

工作经历

西安恒趣信息技术 | 服务端开发

2025.07—2026.03

热血江湖类商业游戏 | Lua 服务端 + Excel 配置驱动 + 客户端 FGUI/Lua 联调

- 参与商业游戏版本迭代, 维护活动、任务、奖励、商城与怪物刷新等**服务端逻辑**, 结合策划配置和客户端表现完成需求落地。
- 开发与维护**攻略系统**、**战令**、**百宝阁**、**首领掉落/争夺**等功能, 覆盖状态处理、奖励发放、客户端入口与数据配置。
- 维护 **Excel** 源表及生成后的 **Lua** 配置, 保证服务端与客户端在物品 ID、任务进度、变量标识、怪物映射和奖励数据上的一致性。
- 通过**日志**、**配置比对**和**跨端联调**定位持久化、奖励格式、怪物刷新、编码与资源引用问题; 文档不完整时还原业务链路, 控制改动范围并完成发布前回归。

其他后端实践

墨香阁社区 | Java 后端与中间件实践

2024.03—2024.06

- 基于 **Spring Cloud** 与 **MyBatis-Plus** 开发文章社区; 使用 **Gateway + JWT** 完成身份认证, 以 **Redis ZSet** 实现延迟发布, 并用 **Elasticsearch** 检索、**Kafka** 异步通知和 **MinIO** 存储媒体资源。
- 通过 **Feign + Sentinel** 完成服务调用与**熔断降级**; 使用 **Swagger**、**Postman** 进行接口开发与功能测试。

个人简介

具备商业游戏服务端**交付经验**, 工作之余持续构建 **RAG 与 LLM 应用**项目, 完成从需求拆解、后端 API、检索评测、自动化测试到 Linux 部署的闭环。

关注**失败样本**、**引用与拒答边界**、**延迟和成本**, 不以单次跑通或单一指标判断效果; 能够阅读存量代码、定位跨模块问题并控制改动范围。

保持**技术记录与复盘**, 累计发布 [CSDN 99 篇原创 \(blog.csdn.net/qq_64669006\)](https://blog.csdn.net/qq_64669006)。

教育背景与技术

咸阳师范学院 | 计算机科学与技术 | 本科 | 专业前 10%

2021.09—2025.06

- 在校开发**: 参与互联网+“解忧维修铺”项目, 负责**微信小程序**主要开发并获**铜奖**; 自学**鸿蒙开发**, **3 次**担任课程设计组长, 负责技术调研、任务拆解与问题解决。
- 组织经历**: 曾任学生会文体部副部长、计算机协会策划部长; 协调校运会 **600+ 人**表演, 组织 **400+ 人**装机大赛, 争取 **8000 元**赞助。